



Universidad Internacional de La Rioja  
Escuela Superior de Ingeniería y Tecnología

Maestría en Inteligencia Artificial

Asignatura: Procesamiento del Lenguaje Natural

## Actividad grupal: Análisis de Sentimientos

Trabajo de innovación presentado por:	Edmilson Prata da Silva Mariana Carmona Cruz Gerardo Davila Pedro Luis Cabrera
Fecha:	10/01/2026

## Índice de contenidos

1. Introducción y Objetivo	3
2. Preguntas sobre el artículo “The state-of-the-art in Twitter sentiment analysis”	3
3. Construcción de un Analizador de Sentimientos	6
4. Preguntas sobre el Analizador de Sentimientos	6
5. Archivos	8

## 1. Introducción y Objetivo

Este trabajo fue desarrollado para atender el requisito de la asignatura de Procesamiento del Lenguaje Natural, de la Maestría en Inteligencia Artificial, de Universidad Internacional de La Rioja, en 2026, hecho por el grupo 1030H.

El objetivo de esta actividad es aplicar los conocimientos adquiridos para resolver un problema de análisis de sentimientos, también conocido como minería de opiniones.

## 2. Preguntas sobre el artículo “The state-of-the-art in Twitter sentiment analysis”

Esta sección responde las preguntas sobre el artículo: Zimbra, D., Abbasi, A., Zeng, D. y Chen, H. (2018). The state-of-the-art in Twitter sentiment analysis: A review and benchmark evaluation. ACM Transactions on Management Information Systems (TMIS), 9(2), 1-29. <https://dl.acm.org/doi/pdf/10.1145/3185045>.

**2.1.** Define con tus propias palabras qué es el Análisis de Sentimientos. ¿Qué tiene de particular el análisis de sentimientos de Twitter (Twitter sentiment analysis, TSA)?

los tuits son muy cortos en el periodo analizado en promedio eran de 140 caracteres, tienen poco contexto semántico, son muy dispersas las representaciones del texto y cuando no hay palabras claramente emocionales es muy difícil identificar el sentimiento.

Por otra parte el lenguaje es cambiante y creativo incluso llega a ser informal con el uso de slangs abreviaturas emojis hashtags que pudieran tener carga de sentimientos errores ortográficos entre otros.

La mayoría de los twits son neutrales, y son pocos los que se pudieran considerar como positivos o negativos hay mucho contexto externo se refieren a un link o alguna situación que está ocurriendo en el momento se supone un conocimiento compartido. Usos de memes, ironías y sarcasmos.

El lenguaje y las emociones cambian con el tiempo, los tuits pueden estar relacionados temporalmente entre sí. Por eso la precisión fue por debajo del 70%.

**2.2.** Usando como punto de partida el propio artículo u otras fuentes, describe en detalle un artículo que proponga un caso de uso concreto de TSA, indicando la arquitectura de su propuesta y los resultados que obtienen. Se trata de presentar una revisión de una solución concreta para el análisis de sentimientos sobre datos de Twitter: resumen general de la idea, descripción de la arquitectura de la solución, resultados obtenidos y resumen de conclusiones.

### **Resumen general de la idea**

El artículo de Zimbra et al. (2018) analiza de forma sistemática el estado del arte en el análisis de sentimientos en Twitter mediante una evaluación comparativa de distintos enfoques. La propuesta consiste en estudiar cómo técnicas léxicas, métodos tradicionales de machine learning y enfoques híbridos se comportan al aplicarse a datos reales de Twitter, caracterizados por su brevedad, informalidad y dependencia del contexto.

### **Arquitectura de la solución**

Aunque el artículo no propone una única herramienta específica, sí describe una arquitectura común de referencia seguida por la mayoría de las soluciones de TSA evaluadas:

#### *1. Adquisición de datos*

Recolección de tuits mediante la API de Twitter o a partir de datasets públicos previamente anotados.

#### *2. Preprocesamiento del texto*

Incluye la normalización del contenido, eliminación de URLs y menciones, tratamiento de hashtags, emojis y corrección de errores ortográficos, con el objetivo de reducir el ruido característico de Twitter.

#### *3. Extracción de características*

Se emplean representaciones basadas en n-gramas, características léxicas, diccionarios de polaridad y, en algunos casos, combinaciones de múltiples fuentes de información.

#### *4. Clasificación del sentimiento*

Se utilizan clasificadores supervisados como Naive Bayes, Support Vector Machines y regresión logística, así como enfoques basados en diccionarios o combinaciones híbridas.

#### *5. Evaluación del rendimiento*

El desempeño de los modelos se mide utilizando métricas estándar como accuracy, precision, recall y F1-score, permitiendo una comparación objetiva entre métodos.

### **Resultados obtenidos**

Los resultados del benchmark muestran que los modelos supervisados suelen obtener mejores resultados que los enfoques puramente léxicos cuando cuentan con datos de entrenamiento adecuados. No obstante, incluso los mejores modelos presentan precisiones moderadas, generalmente inferiores al 70 %, y un rendimiento altamente dependiente del dataset, del dominio y del contexto temporal.

### **Conclusiones**

El estudio concluye que el análisis de sentimientos en Twitter continúa siendo un problema abierto y complejo. Factores como el sarcasmo, la ironía, la falta de contexto y la evolución del lenguaje afectan negativamente al rendimiento de los modelos, lo que pone de manifiesto la necesidad de enfoques más robustos y de datasets de mayor calidad.

**2.3.** A partir de lo analizado en los artículos, enumera qué aspectos del análisis de sentimientos de Twitter se consideran retos abiertos y explica su importancia.

Entre los retos más relevantes se encuentra la detección de sarcasmo e ironía, frecuente en este tipo de mensajes y difícil de identificar sin contexto adicional. A esto se suma la limitación de contexto semántico, derivada de la corta longitud de los tuits, así como la ambigüedad léxica, donde el significado y la polaridad de las palabras dependen del contexto. Otro reto importante es la evolución temporal del lenguaje (concept drift), que provoca la pérdida de efectividad de los modelos entrenados con datos históricos. Finalmente, la escasez de datos anotados de calidad y el ruido inherente a Twitter (spam, bots y errores ortográficos) afectan directamente al rendimiento de los sistemas de análisis de sentimientos, evidenciando que el TSA continúa siendo un problema abierto en el ámbito del procesamiento del lenguaje natural.

**2.4.** Para terminar, nos gustaría que reflexionaras sobre el papel de los datos en la tarea de análisis de sentimientos.

Los datos desempeñan un papel fundamental en la tarea de análisis de sentimientos, ya que la calidad, representatividad y actualidad del conjunto de datos influyen directamente en el rendimiento de los modelos. En el caso de Twitter, los datos presentan un alto nivel de ruido, variabilidad lingüística y dependencia del contexto, lo que dificulta la correcta interpretación del sentimiento. Además, la rápida evolución del lenguaje y de los temas tratados provoca que los modelos entrenados con datos históricos pierdan efectividad con el tiempo. Por ello, resulta esencial contar con datasets bien anotados, actualizados y representativos del dominio, así como con procesos de adaptación y reentrenamiento continuo que permitan mantener la precisión de los sistemas de análisis de sentimientos en entornos reales.

### 3. Construcción de un Analizador de Sentimientos

Construcción de un Analizador de Sentimientos siguiendo las instrucciones del tutorial disponible en [este tutorial](#)<sup>1</sup>.

### 4. Preguntas sobre el Analizador de Sentimientos

Después de la construcción del Analizador de Sentimientos, responda las siguientes preguntas:

**4.1.** Describe el proceso en general: ¿qué problema pretende resolver el tutorial?

El tutorial aborda el problema de adaptar un clasificador de sentimientos preentrenado a un dominio específico sin disponer inicialmente de datos etiquetados. En concreto, muestra cómo mejorar el rendimiento de un modelo de análisis de sentimientos general al aplicarlo a consultas del dominio bancario, mediante un proceso iterativo de predicción, corrección manual de etiquetas y fine-tuning. De este modo, se reduce el impacto del uso de datos fuera de dominio y el esfuerzo de anotación manual.

---

<sup>1</sup> Disponible en <https://rubrix.readthedocs.io/en/master/tutorials/01-labeling-finetuning.html>.

**4.2.** Sobre el proceso en particular: describe paso a paso cómo se consigue obtener un analizador de sentimientos mejor tras adaptar un analizador ya entrenado sobre un conjunto de datos nuevo y cómo se crea ese conjunto de datos nuevo.

El proceso comienza con la selección de un clasificador de sentimientos preentrenado, entrenado originalmente sobre un conjunto de datos genérico. Este modelo se aplica inicialmente sobre un conjunto de textos del nuevo dominio que no cuenta con etiquetas de sentimiento, con el objetivo de obtener una primera aproximación automática a la polaridad de los mensajes.

A continuación, se registran y analizan las predicciones generadas por el modelo, identificando aquellos casos en los que la clasificación no se ajusta a la política de anotación definida para el dominio. Estas predicciones se revisan manualmente y se corrigen cuando es necesario, lo que permite construir un primer conjunto de datos anotado, aunque de tamaño reducido.

Posteriormente, este conjunto de datos se utiliza para realizar un ajuste fino (fine-tuning) del modelo preentrenado, adaptándolo a las características lingüísticas y semánticas del dominio específico. El modelo resultante se aplica de nuevo sobre ejemplos no etiquetados, generando predicciones más alineadas con el contexto del dominio.

Estas nuevas predicciones se revisan nuevamente y se incorporan al conjunto de entrenamiento, ampliándolo con ejemplos adicionales, especialmente aquellos que resultan más informativos o ambiguos. Finalmente, el modelo se reentrena con el conjunto de datos ampliado, obteniendo un analizador de sentimientos con un rendimiento mejorado. Este enfoque iterativo de predicción, anotación y reentrenamiento permite construir progresivamente un clasificador de sentimientos adaptado al dominio partiendo de datos sin etiquetar.

**4.3.** Valora la utilidad de tener un flujo de trabajo como el presentado en el tutorial para trabajar en la tarea de análisis de sentimientos.

El flujo de trabajo presentado en el tutorial resulta especialmente útil para la tarea de análisis de sentimientos, ya que permite adaptar modelos preentrenados a dominios específicos con un esfuerzo reducido de anotación manual. Mediante un proceso iterativo de

predicción, corrección de etiquetas y fine-tuning, se mejora progresivamente el rendimiento del modelo, incluso cuando no se dispone inicialmente de un conjunto de datos etiquetado. Este enfoque facilita la reutilización de modelos existentes y permite responder de forma flexible a cambios en el dominio o en el tipo de datos analizados.

#### 4.3.1. ¿Cómo adaptarías este proceso para trabajar sobre datos de Twitter?

Para aplicar este flujo de trabajo a datos de Twitter, sería necesario incorporar un preprocesamiento específico, incluyendo el tratamiento de hashtags, menciones, emojis y abreviaturas. Además, se deberían definir criterios claros de anotación que contemplen fenómenos como la ironía y el sarcasmo, frecuentes en esta plataforma. Dado el carácter dinámico del lenguaje en Twitter, también sería recomendable realizar reentrenamientos periódicos para mitigar el efecto del concept drift.

#### 4.3.2. ¿Cómo adaptarías el proceso para trabajar sobre datos en castellano?

Para trabajar con datos en castellano, el proceso debería partir de modelos preentrenados en español, como aquellos basados en arquitecturas BERT adaptadas al idioma. Asimismo, sería necesario crear un conjunto de datos anotado en castellano, teniendo en cuenta variaciones regionales y expresiones propias del idioma. El flujo de anotación y fine-tuning se mantendría, permitiendo adaptar el modelo de forma progresiva al contexto lingüístico específico.

## 5. Archivos

Los archivos (entregables) de este trabajo están disponibles en GitHub ([https://github.com/edprata/data-labs/tree/main/analizador\\_de\\_sentimientos](https://github.com/edprata/data-labs/tree/main/analizador_de_sentimientos)).